

Oberseminar Automatisierungstechnik SS2026

YOLO26: Bestimmung von Objekt-Posen in Bildern

Nguyen, Duc Hai; Loewe, Richard

MOTIVATION

Die Wahrnehmung und Interpretation der Umgebung ist eine zentrale Voraussetzung für die Navigation mobiler Roboter. Dynamische Objekte wie Personen erfordern dabei neben der Positionsbestimmung auch die Erfassung von Körperhaltung und Bewegungsabsicht. Die Keypoint-basierte Posenbestimmung mit YOLO26-Pose detektiert Personen und schätzt 17 Körper-Keypoints in Bildern. Dadurch werden eine vorausschauende Kollisionsvermeidung, eine sichere Bahnplanung sowie Anwendungen der Mensch-Roboter-Interaktion ermöglicht.




Abbildung 1: YOLO26-Pose zur Bestimmung von Objekt-Posen in Bildern – Ausgabe mit Bounding Boxes, Konfidenzwerten und Keypoints.

EINGANGSDATEN DES NETZES

Das neuronale Netz verarbeitet Bilder als Tensor der Form

$$\text{Höhe} \times \text{Breite} \times \text{Farbkanäle}$$

YOLO26 verwendet eine feste Eingangsgröße von 640×640 Pixeln mit drei RGB-Farbkanälen:

$$\text{float32}[640, 640, 3]$$

Da Eingangsbilder in der Regel nicht quadratisch sind, werden sie mittels Padding auf die erforderliche Eingabegröße standardisiert. Hierzu wird das Bild zunächst unter Beibehaltung des Seitenverhältnisses auf eine maximale Kantenlänge von 640 Pixeln skaliert und anschließend mit schwarzen Randbereichen (Padding = 0) zu einem quadratischen Bild ergänzt.




Abbildung 2: Anpassung der Eingabedimension mittels Padding

AUSGANGSDATEN DES NETZES

Die Ausgabe des YOLO26-Pose-Netzes erfolgt als Tensor

$$\text{float32}[300, 57]$$

und enthält bis zu 300 potenzielle Detektionen mit Bounding-Box-, Konfidenz- und Keypoint-Informationen. Nach der Konfidenzfilterung verbleiben die tatsächlich erkannten Personen P, sodass ein Tensor der Form [P, 57] entsteht. Anschließend werden Bounding-Boxen und die 17 Körper-Keypoints auf die Originalauflösung des Bildes zurückskaliert.

Professur für
Automatisierungstechnik
Prof. Dr. techn. Klaus Janschek

GESAMTARCHITEKTUR




Abbildung 3: YOLO26 Architekturdiagramm. Quelle: [1]

ZENTRALE BAUSTEINE DER YOLO26-POSE-ARCHITEKTUR

Baustein	Verarbeitung	Funktion im Netz
Conv-Block	Conv2d → BatchNorm → SiLU	Extrahiert Merkmale; halbiert bei Stride 2 die Auflösung.
C3k2-Block	Aufteilung in 2 Pfade → Bottlenecks im Arbeitspfad → Zusammenführung aller Zwischenergebnisse	Verfeinert Merkmale bei gleicher Auflösung; Bypass spart Rechenaufwand und verbessert den Gradientenfluss
SPPF-Block	1×1-Conv → drei serielle 5×5-MaxPool-Schritte → Zusammenführung → 1×1-Conv	Erfasst Bildmerkmale auf verschiedenen Kontextgrößen, ohne die räumliche Auflösung zu reduzieren
C2PSA-Block	Aufteilung der Merkmale → Self-Attention in einem Teilpfad → Zusammenführung	Gewichtet Bildbereiche kontextabhängig




Abbildung 4: Merkmalskarten von Schichten des YOLO26n-Pose-Backbones
Oben: Schichten P1/2 bis P5/32 in ihrer tatsächlichen relativen Größe dargestellt
Mitte: Ausgaben auf einheitliche Anzeigegröße skaliert
Unten: Kanalmittel und sechs ausgewählte Einzelkanäle der P2/4-Stufe

TRAINING

Datensatz: COCO-Pose (COCO Keypoints 2017)
Gesamtverlust:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{box}} \mathcal{L}_{\text{box}} + \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{pose}} \mathcal{L}_{\text{pose}} + \lambda_{\text{kobj}} \mathcal{L}_{\text{kobj}} + \lambda_{\text{RLE}} \mathcal{L}_{\text{RLE}}$$

- $\mathcal{L}_x$: Verlustfunktion der jeweiligen Komponente
- λ_x : Gewicht der jeweiligen Verlustkomponente

YOLO26-Trainingstechniken:

- NMS-frei durchs Training:** Dual-Head — One-to-Many (dichte Supervision) + One-to-One (Inferenzpfad)
- Progressive Loss:** Gewichtung verschiebt sich linear von (0,8 / 0,2) zu (0,1 / 0,9) → Optimierung wandert zum Inferenz-Head
- STAL:** garantiert Zuordnungen für kleine Objekte
- MuSGD:** Hybrid aus Muon + SGD → schnellere Konvergenz
- Kein DFL** → direkte Box-Regression

LAUFZEIT- UND GENAUIGKEITSANALYSE

Testziel: Vergleich der Laufzeit und Erkennungsgenauigkeit von YOLO26n-Pose und YOLO11n-Pose auf verschiedenen Hardwareplattformen.

Testaufbau: Beide Modelle wurden mit identischen Einstellungen auf zwei CPUs und einer CUDA-GPU getestet. Als Datengrundlage dienten zehn Bilder mit mehreren, teilweise stark verdeckten Personen. Die Laufzeiten für Vorverarbeitung, Inferenz und Nachverarbeitung wurden getrennt erfasst und über alle Testbilder gemittelt. Die verwendeten Hardwareplattformen sind in der Abbildung dargestellt.

Ergebnis: Die Nachbearbeitung ist bei YOLO26 auf allen Plattformen kürzer und die Laufzeit stabiler. Der Gesamtvorteil ist jedoch hardwareabhängig: Auf den CPUs ist YOLO26 leicht langsamer auf der GPU schneller. YOLO26-Pose erreicht eine höhere Erkennungsgenauigkeit und erkennt weitere Personen im Hintergrund.



Separated Runtime Components of YOLO Pose Models by Hardware




Abbildung 5: YOLO11n- vs. YOLO26n-Pose
Oben: Qualitativer Vergleich YOLO26 erkennt zusätzlich entfernte Personen.
Unten: Laufzeitkomponenten pro Bild auf zwei CPUs und einer GPU; Fehlerbalken: ± 1 Standardabweichung.

QUELLE

- [1] Glenn Jocher, Jing Qiu, Mengyu Liu, Shuai Lyu, Fatih Cagatay Akyon, Muhammet Esat Kalfaoglu: "Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models". arXiv preprint arXiv:2606.03748, June 2026 (Internet source <https://arxiv.org/pdf/2606.03748>, accessed on 11.07.2026)